

Otonom Hava Sistemleri için Gelişmiş Görüntü İşleme Tabanlı Tehdit Tespiti, Sınıflandırma ve Kaçınma

Eren Altun

Yazılım Mühendisliği Bölümü
Mühendislik ve Doğa Bilimleri Fakültesi
Karabük Üniversitesi
Karabük, Türkiye

Mustafa Kale

Yazılım Mühendisliği Bölümü
Mühendislik ve Doğa Bilimleri Fakültesi
Karabük Üniversitesi
Karabük, Türkiye

Abstract—İnsansız hava araçlarının otonom görevlerdeki kullanımının giderek yaygınlaşması, tehdit tespiti, sınıflandırma ve kaçınma alanlarında yeni çözümlere duyulan ihtiyacı artırmaktadır. Özellikle çekışmeli ve dinamik ortamlarda; görsel bozulmalar, ani değişen tehdit örüntüleri, daha önce karşılaşılmamış İHA tipleri ve kısıtlı tepki pencereleri, mevcut görüntü işleme yöntemlerinin sınırlarını zorlamaktadır. Bu çalışmada, söz konusu ortamlar için YOLO26 mimarisine dayalı derin öğrenme tabanlı tehdit tespiti ve sınıflandırması, pikselden türetilen mesafe kestirimi, kural tabanlı adaptif kaçınma mekanizması ve daha önce görülmemiş İHA tiplerine yönelik saha-içi otonom veri toplama altyapısı geliştirilmiştir. Sistem, üç farklı giriş çözünürlüğüyle (640, 960 ve 1280 piksel) NVIDIA Jetson Orin Nano üzerinde Hardware-in-the-Loop (HIL) testlerine tabi tutulmuştur. Sonuçlar, YOLO26-1280 modelinin 21,6 metre tespit menzili ile en güçlü aday olduğunu ortaya koyarken, Gazebo simülasyon ortamında gerçekleştirilen kaçınma senaryosunda %86,7 başarı oranı elde edilmiştir. Saha-içi otonom veri toplama altyapısı, görülmemiş bir hedefe ait 30 çerçeveyi insan müdahalesi olmaksızın başarıyla derlemiş; bu sayede az örnekle ince ayar için tutarlı bir veri kümesi üretilmiştir.

Index Terms—İnsansız Hava Araçları; Tehdit Tespiti; YOLO26; Az Örnekle Öğrenme; Otonom Kaçınma; Hardware-in-the-Loop; Kenar Hesaplama.

I. GİRİŞ

İnsansız hava araçları (İHA'lar), sınır güvenliği, gözetleme, arama-kurtarma ve savunma gibi alanlarda operasyonel yük taşıyan platformlara dönüşmüştür. Bu görevlerdeki etkinlik, büyük ölçüde tehditlerle karşılaşıldığında hızlı ve güvenilir kararlar alabilme kapasitesine bağlıdır. Bununla birlikte, geleneksel sensör tabanlı sistemler, dinamik ve çekışmeli ortamlarda düşman varlıkları zararsız nesnelerden ayırt etmekte ciddi güçlükler yaşamaktadır [1].

Tehdidin sürekli olarak konum değiştirdiği, görüntü kalitesinin çevresel faktörler nedeniyle bozulduğu ve aynı anda birden fazla hedefin takip edilmesi gereken senaryolar bu güçlükleri daha da derinleştirmektedir. Bu koşullarda, İHA'nın durumsal farkındalığını yitirmeden doğru kararlar alabilmesi, yüksek doğruluklu ve gerçek zamanlı bir görüntü işleme altyapısını zorunlu kılmaktadır [2].

Literatür incelendiğinde, nesne tespiti, tehdit sınıflandırması ve kaçınma bileşenlerinin büyük ölçüde birbirinden

bağımsız olarak geliştirildiği görülmektedir [3]. Entegre sistemler oldukça sınırlıdır ve bunların büyük çoğunluğu yalnızca kontrollü ortamlarda test edilmiştir. Eğitim sırasında hiç görülmemiş yeni dron tiplerinin sınırlı örnekle tanınması ise neredeyse hiç ele alınmamıştır.

Bu çalışmanın temel katkıları şu şekilde özetlenebilir: (i) nesne tespiti, dost-düşman sınıflandırması ve az örnekle adaptasyon bileşenlerini tek bir sistem çerçevesinde ele alan entegre bir mimari; (ii) dinamik operasyonel koşulların getirdiği görsel gürültü, uzak mesafedeki küçük hedefler ve görülmemiş dron tipleri gibi özgül zorlukları hedefleyen yaklaşım; (iii) görülmemiş İHA tiplerinden saha-içi otonom veri toplama ve az örnekle adaptasyonu mümkün kılan altyapı; (iv) tüm bileşenlerin NVIDIA Jetson Orin Nano üzerinde HIL ortamında doğrulanması.

II. İLGİLİ ÇALIŞMALAR

A. İHA'larda Görüntü İşleme Tabanlı Tehdit Tespiti

İHA görüntülerinde nesne tespiti, derin öğrenme yöntemlerinin olgunlaşmasıyla ivme kazanmıştır. YOLO mimari ailesi bu alanda öne çıkmakta; hız ve doğruluk dengesi sayesinde gerçek zamanlı uygulamalarda yaygın biçimde tercih edilmektedir [4]. Wang ve ark. [5], YOLOv8 üzerine inşa edilen hafif bir modelle Visdron veri kümesinde küçük nesne tespitinde umut verici sonuçlar elde etmiş; ancak model mimarisindeki basitleştirme karmaşık arka planlarda performansı olumsuz etkileyebilmektedir. Ning ve ark. [6], özelleştirilmiş bir küçük nesne tahmin kafası ekleyerek mAP@0.5 değerini artırmış; ancak önerilen yöntemin gerçek zamanlı uygulamalarda neden olabileceği işlem gecikmesi, sistem performansını doğrudan etkileyen kritik bir boyut olarak öne çıkmaktadır. SOD-YOLO [7] ve YOLOv8n tabanlı yaklaşımlar [8] da benzer küçük nesne odaklı geliştirmeler sunmaktadır.

B. Derin Öğrenme Tabanlı Nesne Tanıma ve Sınıflandırma

Tek aşamalı nesne tespit yöntemleri, otonom sistemlerde gerçek zamanlı karar alma süreçlerini etkinleştirmeleri açısından ön plana çıkmaktadır [4]. Evrişimli Sinir Ağları (ESA) ve

türevleri, farklı ölçeklerdeki nesnelerin tespiti ve sınıflandırılmasında güçlü ve tutarlı sonuçlar vermektedir [9]. Yüksek belirsizlikli ortamlarda zararsız ve düşman İHA'ların güvenilir biçimde ayırt edilmesi önemli bir araştırma problemi olmaya devam etmektedir.

C. Anomali Tespit Yöntemleri

Anomali tespiti, daha önce tanımlanmamış tehdit türleriyle başa çıkabilme kapasitesi sayesinde nesne tanımaya tamamlayıcı bir yaklaşım olarak öne çıkmaktadır [10]. Özellikle tek sınıflı öğrenme ve otokodlayıcı tabanlı yöntemler, yalnızca normal örneklerden öğrenerek anormal durumları tespit etmede etkili sonuçlar verebilmektedir [11]. Bu yaklaşımların gerçek zamanlı kaçınma sistemleriyle entegre uygulaması henüz yeterli olgunluğa ulaşamamış; işlem gecikmesi ve eşik değeri belirleme gibi pratik sorunlar literatürde sınırlı düzeyde ele alınmıştır.

D. Az Örnekle Öğrenme ve Görülmemiş Hedeflere Uyarlama

Az örnekle öğrenme (few-shot learning), bir modelin yeni bir sınıfı yalnızca birkaç etiketli örnekten genellebilemesini hedefler. Eşleştirme ağları [12] ve prototip ağları [13] gibi metrik tabanlı yaklaşımlar, örnekleri ortak bir gömme uzayında temsil ederek tek ya da birkaç örnekten sınıflandırma yapılabilmesini sağlamıştır. Az örnekli nesne tespitine yönelik çalışmalar da mevcuttur [14]; ancak bu yöntemlerin İHA platformlarında saha-ıçi ve gerçek zamanlı koşullarda, daha önce hiç görülmemiş dron tiplerine uyarlanmasına yönelik çalışmalar oldukça sınırlı kalmaktadır.

E. Kaçınma Sistemleri ve Literatürdeki Boşluklar

Potansiyel alanlara [15] ve hız engellerine [16] dayalı klasik kaçınma yöntemleri, statik ya da sınırlı manevra kabiliyetine sahip engeller için etkin çözümler sunmaktadır. Ancak bu yaklaşımlar, aktif manevra gerçekleştiren tehditlere karşı yetersiz kalmaktadır. Derin pekiştirmeli öğrenme tabanlı yaklaşımlar [17], [18] simülasyon ortamında test edilmiş olmakla birlikte, gerçek zamanlı yanıt süresinin ayrıntılı biçimde analiz edilmemesi pratik uygulanabilirliklerini kısıtlamaktadır. Bu çalışmada tespit, tehdit değerlendirme ve kaçınma süreçleri entegre bir yapı içinde ele alınarak mevcut literatürdeki eksikliğe doğrudan yanıt verilmesi amaçlanmıştır.

III. ÖNERİLEN YÖNTEM

A. Sistem Mimarisine Genel Bakış

Önerilen sistem, birbirleriyle etkileşim halinde çalışan üç temel bileşenden oluşmaktadır: görüntü algılama, dost-düşman sınıflandırması ve az örnekle adaptasyon. Şekil 1'de sunulan mimari, Gazebo, ROS2, YOLO26 ve bileşenlerini kapsayan üst düzey sistem entegrasyon diyagramını göstermektedir. Görüntü algılama bileşeni, ROS2 konusu üzerinden İHA kamerasından elde edilen görüntü akışını işleyerek sahnedeki nesneleri tespit etmektedir. Sınıflandırma bileşeni, tespitleri dost, düşman ve genel (bilinmeyen) kategorilerine ayırmaktadır. Az örnekle adaptasyon bileşeni, bilinen sınıflara girmeyen hedefler tespit edildiğinde çok açılı ve otomatik etiketli görüntüler

toplayarak modelin sınırlı örneklerle yeni tipe uyarlanabilmesi için gerekli veriyi üretmektedir. Bileşenler arasındaki iletişim ROS2 altyapısı üzerinden sağlanmakta; ArduPilot'a iletilen eylem komutları MAVLink protokolü ile yürütülmektedir.

Sistem, NVIDIA Jetson Orin Nano görev bilgisayarı entegre edilerek HIL ortamında test edilmiştir. Bu yapılandırmada simülasyon ana bilgisayarda çalışmaya devam ederken model çıkarımı ve hareket komutu üretimi Orin üzerinde gerçekleştirilmiş; iki sistem arasındaki iletişim LAN (Ethernet) bağlantısı üzerinden sağlanmıştır.




Fig. 1

B. Tehdit Tespiti: YOLO26 Mimarisi

Nesne tanıma bileşeni için birincil mimari olarak Ultralytics YOLO26 benimsenmiştir. YOLO26, uç cihazlar ve düşük güç tüketen sistemler için sıfırdan tasarlanmış, YOLO serisinin en güncel mimarisidir. Mimarinin tasarımı üç temel ilke üzerine kurulmuştur: *basitlik*, *dağıtım verimliliği* ve *egitim yenilikleri*. Bu ilkeler doğrultusunda YOLO26, geleneksel dedektörlerde zorunlu bir son işlem adımı olan maksimum bastırma (NMS) aşamasını tamamen ortadan kaldırmış; tahminleri doğrudan üretebilen, uçtan uca yerel bir model olarak tasarlanmıştır [19].

YOLO26'yı önceki yaklaşımımızda kullandığımız YOLOv8'den ayıran başlıca mimari özellikler şunlardır:

- **NMS'siz uçtan uca çıkarım:** Tahminler doğrudan üretildiğinden gecikme azalmakta ve üretim sistemlerine entegrasyon hızlanmaktadır.
- **DFL kaldırma:** Dağıtım Odak Kaybı (DFL) modülü dışarıda bırakılmış; bu sayede çıkarım basitleştirilmiş ve uç cihazlarla donanım uyumluluğu genişletilmiştir.
- **ProgLoss + STAL:** İyileştirilmiş kayıp fonksiyonları küçük nesne tanıma performansını artırmakta; bu özellik hava görüntüleme uygulamaları için kritik önem taşımaktadır.
- **MuSGD optimize edici:** SGD ile Muon'u birleştiren hibrit optimize edici daha kararlı eğitim ve daha hızlı yakınsama sağlamaktadır.
- **CPU çıkarım hızı:** GPU bulunmayan cihazlarda CPU çıkarım hızını %43'e kadar artırmaktadır.

- **Mimari sağlamlık:** YOLOv8'de aşırı veri artırma uygulandığında gözlemlenen doğruluk düşüşü YOLO26'da büyük ölçüde giderilmiştir.

Bu projede iki temel çözünürlük değerlendirilmektedir: YOLO26-640 (düşük gecikme) ve YOLO26-1280 (geniş tespit menzili). HIL testlerinde ayrıca 1280 piksellik modelin engine dönüşümü sırasında giriş çözünürlüğü 960 piksele indirilerek elde edilen YOLO26-960 ara varyantı da değerlendirilmiştir. YOLO26 mimarisinin yapısı Şekil 2'de gösterilmektedir. CSP-Net tabanlı omurga, çok ölçekli Neck ve çapa noktasından bağımsız tespit kafaları (Head) uçtan uca gerçek zamanlı tespit sağlamaktadır.




Fig. 2

C. Çok İş Parçacıklı Yazılım Mimarisi

Gerçek zamanlı tepki gereksinimi, sistemin dört paralel iş parçacığına ayrılmasıyla karşılanmıştır. İş parçacıkları arasındaki veri alışverişi, maxsize=1 parametresiyle yapılandırılmış Queue nesneleri üzerinden gerçekleştirilmektedir. Bu yapı, eski verinin tutulmamasını ve her iş parçacığının daima en taze tespit sonucuyla çalışmasını garanti etmektedir.

- **T1–Tespit:** GazeboSource bileşeni aracılığıyla /iris_1/camera/image/compressed ROS2 topic'inden sıkıştırılmış görüntü alır, YOLO26 çıkarımını yürütür ve sonucu detection_queue'ya yazar.
- **T2–Kontrol:** Tespit sonucunu okuyarak $V_x/V_y/V_z/Yaw$ komutlarını hesaplar; OrbitCollector ve FewShotTracker bileşenlerini yönetir.
- **T3–MAVLink:** Hesaplanan hız komutlarını MAVLink SET_POSITION_TARGET mesajları aracılığıyla ArduPilot'a 20 Hz hızında iletir. RTL komutu, normal hareket kanalından bağımsız rtl_queue üzerinden taşınarak ezilmesi önlenmektedir.
- **T-RTL–Terminal Dinleyici:** Operatörün terminale rtl yazıp Enter tuşuna basması durumunda anlık RTL komutu sisteme iletilir ve tespit döngüsü durdurulur.

Sistem aynı zamanda CSV tabanlı uçuş kaydedici (FlightLogger) ile donatılmış olup her kontrol kararı zaman damgası, eylem, çap, büyüme hızı, panik seviyesi, hız komutları ve gecikme süresiyle birlikte kaydetmektedir.

D. Akıllı Kaçınma Mekanizması

Kaçınma bileşeni, önceki aşamada araştırılan Derin Belirleyici Politika Gradyanı (DDPG) yaklaşımının yerini alan kural tabanlı adaptif bir kontrol mimarisi olarak yeniden tasarlanmıştır. DDPG tabanlı politika, simülasyon ortamında ödül fonksiyonunun tasarlanması ve öğrenme sürecinin yönetilmesi açısından önemli karmaşıklıklar barındırmaktadır. Buna karşın, gerçek zamanlı tehdit kaçınmasında belirleyici olan bilgiler doğrudan ve düşük gecikmeli biçimde ölçülebilmektedir. Bu gözlemden hareketle, yorumlanabilir, deterministik ve anlık olarak ayarlanabilir bir kural tabanlı yaklaşım benimsenmiştir.

1) **Tehdit Düzeyi Kestirimi:** Kaçınma algoritmasının temelini oluşturan tehdit değerlendirmesi iki temel ölçüye dayanmaktadır:

- **Anlık sınır kutusu çapı (b):** Tespit edilen düşman İHA'nın piksel cinsinden sınır kutusu çapı. Düşman ekranda ne kadar büyük görünüyorsa o kadar yakındır.
- **EMA büyüme hızı ($\dot{b}$):** Son karelerdeki çap değişimlerinin üstel hareketli ortalama (EMA, $\alpha = 0.6$) ile düzleştirilmiş oranı. $\dot{b} > 0$ ise hedef yaklaşmaktadır. Ani gürültüye karşı dayanıklılık için anlık oran ile EMA oranının ağırlıklı birleşimi panik hesabında kullanılmaktadır.

Bu iki ölçü birlikte değerlendirilerek $[0, 1]$ aralığında normalize edilmiş bir panik katsayısı p hesaplanmaktadır:

$$p = \min\left(\frac{\max(\dot{b}, 0)}{\dot{b}_{\text{panik}}}, 1\right) \quad (1)$$

Büyüme hızı eşik değerini ($\dot{b}_{\text{panik}} = 2.0$ px/kare) aştığında $p = 1$ olur ve sistem tam panik moduna geçer. Anlık oran da %70 ağırlıklı panik hesabına dahil edilerek erken uyarı kapasitesi artırılmıştır.

Hedef konum tahmini için e_x ve e_y eksenlerinde bağımsız çalışan 1-B Kalman filtreleri uygulanmaktadır (süreç gürültüsü $q = 1.0$, ölçüm gürültüsü $r = 25.0$). Kontrol yasaları ham ölçüm yerine Kalman'ın 100 ms ilerisi için ürettiği pozisyon tahminini kullanmaktadır.

2) **Eksen Bazlı Kontrol Yasaları:** Kaçınma algoritması her eksen için bağımsız bir kontrol yasası üretmekte; durum makinesi kararı histerezis mekanizmasıyla stabilize edilmektedir (aday durum en az 2 ardışık karede onaylanmadan geçiş yapılmaz, KAÇ durumu doğrudan tetiklenir).

a) **İleri-Geri Hızı (V_x):** Düşman çapı tehdit eşikini aştığında ($b \geq b_t = 115$ px) veya büyüme hızı eşikini geçildiğinde ($\dot{b} > 0.8$ px/kare) kaçış modu etkinleşir:

$$V_x = -\left(K_1 \frac{b - b_t}{b_t} + K_2 \max(\dot{b}, 0) + K_3 p\right) \quad (2)$$

Burada $K_1 = 5.0$, $K_2 = 1.2$, $K_3 = -4.5$ 'tir. Panik modunda ($p > 0.7$) maksimum kaçış önceliği yana kaçışa devredilir.

Hedef çok uzaklaştığında ($b < b_f = 45$ px) elde etme modu etkinleşir:

$$V_x = \min\left(0.6 K_1 \frac{b_t - b}{b_t}, 0.5 V_{x,\max}\right) \quad (3)$$

b) **Yanal Hız (V_y) ve Yaw Oranı (ψ)**: Panik katsayısına göre ölçeklenen yaw oranı:

$$\gamma_{yaw} = 1 - p(1 - 0.4) \quad (4)$$

$$\dot{\psi} = \text{clamp}\left(K_{yaw} \cdot \gamma_{yaw} \cdot \frac{e_x}{W/2}, -\dot{\psi}_{\max}, \dot{\psi}_{\max}\right) \quad (5)$$

Burada $K_{yaw} = 2.0$ rad/s ve $\dot{\psi}_{\max} = 1.5$ rad/s'dir. Yüksek panik ($p > 0.7$) durumunda yaw bastırılarak yanal kaçışa öncelik verilir ve geometrik kaçış yönü (düşmanın geldiği tarafın tersi) aktifleşir:

$$V_y = \text{clamp}\left(K_{lat} \cdot p \cdot 1.2 \cdot \frac{e_x}{W/2}, -V_{y,\max}, V_{y,\max}\right) \quad (6)$$

Burada $K_{lat} = 5.0$ m/s'dir.

c) **Dikey Hız (V_z)**: Hedefin kamera çerçevesindeki dikey sapması merkez toleransını (± 70 px) aşarsa hizalama hareketi üretilir:

$$V_z = \text{clamp}\left(K_{vert} (1 + p \cdot 0.5) \frac{e_y}{H/2}, -V_{z,\max}, V_{z,\max}\right) \quad (7)$$

Burada $K_{vert} = 2.0$ m/s'dir. Hedef merkezde ancak $p > 0.6$ ve KAÇ durumu aktifse NED çerçevesinde yukarı doğru ek kaçış ivmesi uygulanır: $V_z \leftarrow V_z - 0.4 V_{z,\max} \cdot p$.

Tespit kaybı durumunda sistem hızlarını kademeli olarak söndürmektedir (%20 oranında decay, 8 kare boyunca). Bu sayede kısa süreli çerçeve kayıplarında ani dur-kalk titremesi önlenmektedir.

Tablo I nihai parametre kümesini özetlemektedir. Bu değerler, Gazebo simülasyon testleri sürecinde config.yaml üzerinden deneysel olarak ayarlanmıştır.

E. Saha-İçi Otonom Veri Toplama ve Az Örnek Adaptasyon

Operasyonel ortamda sistemin eğitim kümesinde yer almayan dron tipleriyle karşılaşması olasıdır. Bu durumu ele almak için veri setine Tip G sınıfı eklenmiştir; bu sınıf bilinen altı sınıfa uymayan tüm hava araçlarını kapsamaktadır.

Tip G olarak algılanan ve güvenli mesafe bandında kararlı biçimde izlenen bir hedef belirlendiğinde (8 stabil kare sonrası), **OrbitCollector** bileşeni hedefi farklı görüş açılarından görüntülemek üzere dönüşümlü sağ ve sol yatay tarama (sweep) hareketleri gerçekleştirir ($V_y = \pm 0.8$ m/s, 4 s/yön). Tarama sırasında 1.5 sn arayla temiz çerçeveler kaydedilir. Etiket üretimi tamamen otomatiktir: her çerçeve için tespit edilen sınırlayıcı kutu koordinatları normalize

TABLE I: Kontrol Sistemi Parametre Özeti

Parametre	Değer	Açıklama
b_t	115 px	Kaçış tetik eşiği (yakl. 6 m)
b_{ideal}	86 px	Hedef gözlem çapı (yakl. 8 m)
b_f	45 px	Uzak mesafe eşiği
b_{too_close}	130 px	Panik mesafesi (yakl. 4 m)
$\dot{b}_t$	0.8 px/kare	Büyüme hızı tetik eşiği
$\dot{b}_{panik}$	2.0 px/kare	Panik büyüme hızı eşiği
K_1 (evade)	5.0	Kaçış kazancı
K_2 (growth)	1.2	Büyüme hızı kazancı
K_{yaw}	2.0	Yaw kazancı
K_{lat}	5.0	Yanal kaçma katsayısı
K_{vert}	2.0	Dikey kaçma katsayısı
$V_{x,\max}$	5.0 m/s	Max ileri-geri hız
$V_{y,\max}$	4.0 m/s	Max yanal hız
$V_{z,\max}$	3.0 m/s	Max dikey hız
$\dot{\psi}_{\max}$	1.5 rad/s	Max yaw hızı
EMA α	0.6	Büyüme hızı düzeltirme

edilerek YOLO formatında etiket dosyasına yazılır. Böylece herhangi bir manuel müdahaleye gerek kalmadan, doğrudan eğitime sokulabilecek formatta etiketli veri üretilmektedir. İnsan iş yükünü ortadan kaldıran bu otonom etiketleme altyapısı saha koşullarında az örnekle adaptasyonu pratik olarak uygulanabilir kılacaktır.

Toplanan verinin tek bir hedefe ait kalmasını güvence altına almak için **FewShotTracker** bileşeni görsel imza tabanlı kimlik takibi (re-identification) mekanizması kullanmaktadır. Hedef ilk görüldüğünde sınırlayıcı kutu bölgesi HSV renk uzayına dönüştürülür; ışık değişimine daha dayanıklı olan H ve S kanallarından 32 bin ayrımlı histogramlar çıkarılarak birleştirilmektedir. İlk birkaç görünüm boyunca bu histogramların ortalaması alınarak temsili bir prototip imza oluşturulur (en fazla 10 örnek, few-shot öğrenmenin sezgisiyle örtüşür). Hedef kameradan çıkıp yeniden görüldüğünde önce konum/boyut benzerliği (tolerans 250 px), ardından histogram korelasyonu (eşik 0.35) birlikte değerlendirilerek hedef kimliği korunur ve her hedefe kalıcı bir ID atanır.

IV. UYGULAMA VE DENEYSEL KURULUM

A. Yazılım ve Donanım Ortamı

Bu çalışmada sunulan tüm çalışmalar, Ubuntu 22.04 LTS işletim sistemi çalışan, Intel Core i5 12. nesil CPU, 16 GB RAM ve 6 GB GDDR6 VRAM'e sahip NVIDIA GeForce RTX 3060 GPU ile donatılmış bir ana makine üzerinde gerçekleştirilmiştir. Model eğitimi ve çıkarımı için CUDA 12.1 destekli PyTorch 2.2.2 kullanılmıştır. Simülasyon altyapısı ROS2 Humble ve ArduPilot SITL ile entegre Gazebo Harmonic üzerine kurulmuştur. Python 3.10.6, veri işleme ve sistem kontrolü için birincil betik dili olarak kullanılmıştır.

HIL doğrulaması için hedef görev bilgisayarı olarak NVIDIA Jetson Orin Nano kullanılmıştır. Gazebo simülasyonu dizüstü bilgisayar üzerinde çalıştırılmış; nesne tespit ve sınıflandırma modelleri Jetson üzerinde TensorRT .engine biçiminde derlenerek gerçek zamanlı olarak yürütülmüştür.

Kamera görüntüleri ROS2 üzerinden Jetson'a aktarılmış; tespit sonuçları ve hareket komutları tekrar ROS2 aracılığıyla simülasyon ortamına iletilerek algılama-analiz-kontrol döngüsü kapalı çevrim olarak tamamlanmıştır.

B. Senaryo Yapısı ve Düşman İHA Kodlaması

Kaçınma testlerini gerçekçi ve tekrarlanabilir kılmak amacıyla simülasyonda iki ayrı İHA örneği kullanılmıştır: kaçan sistem (iris_1) ve onu kovalayan düşman İHA (iris_2). Düşman İHA, sabit bir PID yörünge takip kontrolörüyle kaçan sistemi hedef alacak biçimde programlanmış; değişken ivme profilleri ve yön değişiklikleriyle gerçekçi bir saldırı senaryosu oluşturulmuştur. Her iki İHA da aynı YOLO26 model ailesiyle eğitilmiş görüntülerle temsil edilmekte olup düşman olarak tanımlanan iris-red sınıfı hem kaçınma hem de saha-içi veri toplama testlerinde hedef dron olarak kullanılmıştır. Bu iki-dron senaryosu, kaçınma başarı oranının gerçekçi bir tehdit altında ölçülmesini sağlamıştır.

C. Veri Kümesi Oluşturma ve Otonom Etiketleme

Eğitim ve test verileri tamamen Gazebo simülasyon ortamında üretilmiştir. Veri kümesi, renk ve yapısal özellikleri bakımından birbirinden belirgin biçimde ayrılan toplam 7 sınıf üzerine kurulmuştur: 0: Tip A, 1: Tip B, 2: Tip C, 3: Tip D, 4: Tip E, 5: Tip F ve 6: Tip G. Senaryo düzeyinde gerçekçi bir sınıflandırma altyapısı oluşturmak amacıyla bu sınıflar üç dost dron (Tip A, Tip B, Tip C), üç düşman dron (Tip D, Tip E, Tip F) ve bir genel dron (Tip G) olacak şekilde gruplandırılmıştır.

Her sınıf için dört görsel senaryo kategorisinde dengeli örnekleme sağlanmıştır: standart aydınlatma, düşük parlaklık, yüksek kontrast/renk kayması ve hareket bulanıklığı. Poz çeşitliliğini en üst düzeye çıkarmak için dron modelleri rastgele konum, yönelim, irtifa ve mesafelere yerleştirilmiştir. Eğitim ve test verileri bilinçli olarak farklı simülasyon dünyalarında üretilmiş; bölümlenme kare yerine yörünge düzeyinde gerçekleştirilerek veri sızıntısı önlenmiştir.

Sınır kutusu etiketleri, geliştirdiğimiz otonom etiketleme yazılımı aracılığıyla insan müdahalesi olmaksızın üretilmiştir. Gazebo sahne grafiğinden okunan dron dünya koordinatları, kalibre edilmiş kamera iç matrisi (odak uzaklığı $f = 1253.0$ px) kullanılarak görüntü düzlemine yansıtılmış ve piksel hassasiyetinde sınır kutusu koordinatları YOLO formatında otomatik olarak yazılmıştır. Bu yaklaşım, veri toplamının insan iş yükünü pratik olarak sıfıra indirmektedir. Eksiksiz veri kümesi %80:%10:%10 oranında eğitim, doğrulama ve test kümelerine bölünmüştür.

D. Karşılaştırmalı Model Eğitim Süreci

Bu çalışmada YOLOv8m ve YOLO26m modelleri birlikte değerlendirilmiş, her iki mimari de ön eğitilmiş kontrol noktalarından başlatılarak simülasyon türevi veri kümesi üzerinde ince ayar sürecine tabi tutulmuştur. Karşılaştırmamızın adil ve tutarlı olması amacıyla parti boyutu, epoch sayısı, öğrenme oranı çizelgesi ve optimize edici parametreleri iki model için eşit tutulmuştur. Her iki model 640×640 ve 1280×1280

piksel olmak üzere iki farklı giriş boyutuyla ayrı ayrı eğitilmiş ve değerlendirilmiştir.

Veri artırma parametreleri model grupları arasında bilinçli biçimde farklılaştırılmıştır. YOLOv8-v2 ile YOLO26-640, tespitle ilgili tüm veri artırma parametreleri bakımından birebir aynı yapılandırmayı paylaşmaktadır; dolayısıyla bu iki model arasındaki performans farkları yalnızca mimari tercihten kaynaklanmaktadır. YOLO26-1280 ise daha zorlu bir augmentation kümesiyle eğitilmiş; döndürme açısı ve öteleme genişletilmiş, flipud ve mixup devreye alınmıştır. Bu tercih, yüksek çözünürlükte nesnelerin görece daha büyük görünmesiyle birlikte modelin farklı açı ve pozisyon senaryolarına dayanıklılığını artırmak amacıyla yapılmıştır. Tablo II üç modelin tespitle ilgili veri artırma parametrelerini özetlemektedir.

TABLE II: Model Başına Tespit Veri Artırma Parametreleri

Parametre	YOLOv8-v2	YOLO26-640	YOLO26-1280
mosaic	1.0	1.0	1.0
scale	0.9	0.9	0.9
fliplr	0.5	0.5	0.5
degrees	15	15	20
translate	0.1	0.1	0.3
copy_paste	0.3	0.3	0.2
flipud	0.0	0.0	0.2
mixup	0.0	0.0	0.15




Fig. 3

E. Mesafe Tahmin Modülü

Mesafe tahmin modülü, tespit omurgasından bağımsız çalışmakta ve her onaylanan tespit üzerinde bir son işlem adımı olarak uygulanmaktadır. Kalibre edilmiş odak uzaklığı $f = 1253.0$ px ve hedef dron sınıfının bilinen fiziksel kanat açıklığı $W_g = 0.55$ m verildiğinde, tahmini mesafe d şu şekilde hesaplanmaktadır:

$$d_{\text{est}} = \frac{f \cdot W_g}{w} \quad (8)$$

Bu formülasyon iğne deliği kamera modelini ve hedefin cepheden görünümünü varsaymaktadır. Değerlendirme amacıyla kullanılan gerçek zemin referanslı mesafe değerleri doğrudan Gazebo sahne grafiğinden alınmaktadır.

F. Değerlendirme Metrikleri

Model karşılaştırması aşağıdaki metrikler üzerinden gerçekleştirilmiştir:

- **Maksimum güvenilir tespit mesafesi (m):** 0.30 güven eşliğinde en az 2 ardışık karede sürekli tespit koşulunun sağlandığı maksimum mesafe.
- **Çıkarım hızı (FPS):** Saniyede işlenen ortalama kare sayısı.
- **Sınıflar arası karışıklık:** Mesafe artışıyla birlikte modelin hedef sınıfını yanlış etiketleyip etiketlemediği.
- **Sistem kaynak kullanımı:** GPU ve CPU kullanımı, RAM ve sıcaklık değerleri (HIL testleri için).

V. SONUÇLAR VE TARTIŞMA

Bu bölümde sunulan sonuçlar iki aşamadan elde edilmiştir: (1) ana makine üzerinde Gazebo simülasyon ortamında gerçekleştirilen model karşılaştırması, (2) NVIDIA Jetson Orin Nano üzerindeki HIL doğrulama testleri.

A. Nesne Tespit Performansı: Simülasyon Sonuçları

Karşılaştırmalı model değerlendirmesi kapsamında YOLOv8-v2, YOLO26-640 ve YOLO26-1280 mimarileri değerlendirilmiştir. Modellerin mesafe bazlı doğruluk performansı Şekil 4'de grafik biçimde sunulmaktadır.




Fig. 4

En az 2 ardışık karede sürekli tespit koşulu esas alındığında, 0.30 güven eşliğindeki maksimum güvenilir tespit mesafeleri şu şekilde ölçülmüştür: YOLOv8-v2'de **6.3 m**, YOLO26-640'ta **9.0 m** ve YOLO26-1280'de **18.3 m**. 9 m ile 18 m arasındaki tespit menzili farkı, sistemin bir hedefi erken algılayıp durumsal farkındalık oluşturmak için sahip olduğu süreyi yaklaşık ikiye katlamaktadır.

Sınıflar arası karışıklığın başladığı mesafe de modeller arasında belirgin biçimde farklılaşmaktadır: YOLOv8-v2'de 6.5 m, YOLO26-640'ta 12.7 m ve YOLO26-1280'de 22.9 m. Bu mesafe, doğru sınıflandırmaya dayalı operasyonel kararların güvenle alınabileceği çalışma penceresini doğrudan belirlemektedir.

Şekil 5, YOLO26 modelinin operasyonel mesafe aralığında üç farklı drone sınıfını aynı sahnede eş zamanlı ve doğru biçimde sınıflandırabildiğini göstermektedir.




Fig. 5

Buna karşılık, YOLOv8-v2 modelinin mesafe artışına bağlı sınıflandırma hatası Şekil 6'da gösterilmektedir. 8.48 m mesafede model hedefi yalnızca 0.47 güven puanıyla yanlış sınıflandırmakta; 4.08 m mesafede ise 0.88 güven puanıyla doğru tanımaktadır.



(a) 8.48 m: yanlış sınıflandırma, güven 0.47

(b) 4.08 m: doğru sınıflandırma, güven 0.88

Fig. 6

Üç modelin temel performans metrikleri Tablo III'de özetlenmektedir.

TABLE III: Simülasyon Model Performans Özeti (0.30 Güven Eşiği, ≥ 2 Ardışık Kare)

Model	Maks. Tespit Mesafesi (m)	Ort. FPS	Sınıf Karışıklığı
YOLOv8-v2	6.3	~28	Var (>6.5 m)
YOLO26-640	9.0	~28	Var (>12.7 m)
YOLO26-1280	18.3	~21	Var (>22.9 m)

B. Hardware-in-the-Loop (HIL) Doğrulama Sonuçları

HIL doğrulamasında hedef sınıf iris-red olarak belirlenmiş; iki İHA eş zamanlı olarak havada tutulmuş, hedef 10 m yükseklikte 35 m mesafeye kadar uzaklaşmıştır. Karşılaştırmaya YOLO26-640 ve YOLO26-1280'e ek olarak YOLO26-960 ara varyantı da dahil edilmiştir. 0–25 m aralığındaki kayıtlar esas alınmış; yalnızca en az iki ardışık karede tutarlı biçimde görünen tespitler geçerli sayılmıştır.

HIL ortamında elde edilen sonuçlar Tablo IV'de özetlenmektedir. Giriş çözünürlüğü ile maksimum güvenilir tespit mesafesi arasındaki doğrudan ilişki açıkça görülmektedir: YOLO26-640

hedefi **11.5 m**'ye, YOLO26-960 **15.4 m**'ye ve YOLO26-1280 **21.6 m**'ye kadar güvenilir biçimde tespit etmiştir.

TABLE IV: HIL Doğrulama Performans Özeti (Jetson Orin Nano, 0–25 m)

Model	Maks. Mes.(m)	Ort. Güven	GPU (%)	RAM (MiB)	FPS
YOLO26-640	11.5	0.699	63.8	4709	22–23
YOLO26-960	15.4	0.734	68.3	4186	15–16
YOLO26-1280	21.6	0.703	73.2	4190	11–12

Üç modelin Jetson üzerindeki mesafeye bağlı güven profilleri Şekil 7'de verilmektedir.



Fig. 7

HIL doğrulamasının ortaya koyduğu en kritik mühendislik bulgusu, ham çıkarım hızı ile uçtan uca döngü hızı arasındaki ayırımdır. Modellerin Jetson üzerindeki ham çıkarım kapasitesi 22–23 FPS (640), 15–16 FPS (960) ve 11–12 FPS (1280) olarak ölçülmüş; buna karşın simülasyon haberleşmesi ve entegrasyon yükü nedeniyle kapalı HIL döngüsü etkin olarak her kareyi yaklaşık 1.5 saniyede (~ 0.67 Hz) işleyebilmiştir. Bu ayırım, gerçek bir uçuşta simülasyon haberleşmesi ortadan kalkacağından döngü hızının büyük ölçüde modelin çıkarım hızına yaklaşması beklendiğini ortaya koymaktadır. Yanlış pozitif davranışı açısından üç model de düşük düzeyde halüsinasyon sergilemiştir: YOLO26-640'ta 2, YOLO26-960'ta 4 ve YOLO26-1280'de 3 kayıta hedef dışı sınıf görülmüştür. En az iki ardışık kare koşulunun uygulanmasıyla bu anlık yanılsamaların büyük bölümü elenmiştir.

C. Kaçınma Performansı

Gazebo simülasyon ortamında tek rakip İHA ile gerçekleştirilen yaklaşık 47 saniyelik test boyunca sistemin durum dağılımı şu şekilde oluşmuştur: ORBIT modu 785 döngü

(%83.2), KAÇ modu 81 döngü (%8.6), MESAFE_KOR modu 50 döngü (%5.3), BEKLE modu 28 döngü (%2.9). YAKLAŞ durumuna hiç girilmemiştir; bu durum sistemin düşmanla sürekli optimal mesafe aralığında kaldığını göstermektedir. Toplam 16 kaçınma girişimi tespit edilmiş, bunların 13'ü başarıyla tamamlanmıştır. **Kaçınma başarı oranı %86.7** olarak ölçülmüştür. Başarısız 3 girişim, sistemin KAÇ modundan BEKLE moduna düşmesinden kaynaklanmış olup kısa süreli tespit kaybıyla ilişkilendirilmiştir. Panik modu test boyunca toplam 25 kez tetiklenmiştir.

Test süresince düşman İHA'nın en yakın yaklaşma mesafesi **2.8 m** olarak kaydedilmiştir. Bu değer, 4 m olarak belirlenen güvenli mesafe sınırının altında kalmakta; düşmanın yüksek ivmeli yaklaşması sırasında kaçış hızının yetersiz kaldığı anlarda gerçekleştiği değerlendirilmektedir. Operasyonun büyük bölümünde sistem, hedeflenen 8 m'lik ideal operasyon mesafesi aralığında seyretmiştir.

Her kontrol kararı FlightLogger bileşeni aracılığıyla zaman damgası, durum, çap, büyüme hızı, panik seviyesi ve hız komutlarıyla birlikte CSV formatında kaydedilmiştir. Şekil 8'de kaçınma testi sırasında ekranda görüntülenen HUD çıktısı; Şekil 9'de ise eş zamanlı olarak kaydedilen CSV log içeriği sunulmaktadır.




Fig. 8

Fig. 9

D. Az Örneklerle Veri Toplama Bulguları

OrbitCollector ve FewShotTracker bileşenlerinden oluşan saha-içi otonom veri toplama altyapısı, Tip G sınıfına ait

bir hedef üzerinde test edilmiştir. Sistem, hedefi farklı görüş açılarından görüntüleyerek hedeflenen **30 keşif çerçevesinin tamamını** başarıyla toplamış ve her çerçeve için sınırlayıcı kutu koordinatları normalize edilerek YOLO formatında etiket otomatik olarak üretilmiştir. FewShotTracker, hedefe ait kimliği hedefin kamera dışına çıkıp geri girmesi durumlarında dahi kesintisiz biçimde korumuştur.

Şekil 10'de toplanan örnek çerçeveler, Şekil 11'de ise her çerçeveye karşılık otomatik üretilen YOLO etiket dosyaları görülmektedir.




Fig. 10




Fig. 11

Frame toplama tamamlandıktan sonra sistem 2 saniyelik güvenli uzaklaşma gecikmesinin ardından otomatik olarak RTL (Return-to-Launch) modunu tetiklemiş ve eve dönüş başarıyla gerçekleştirilmiştir.

E. Tartışma

Simülasyon ve HIL sonuçları birlikte değerlendirildiğinde, önerilen entegre algı-sınıflandırma-adaptasyon mimarisinin yüksek doğruluklu ortamlarda teknik olarak uygulanabilir olduğu ve tüm bileşenlerin gerçek kenar donanımı üzerinde başarıyla çalıştığı görülmektedir.

YOLO26 mimarisinin küçük nesne tespitine yönelik tasarım tercihleri, sınıflandırma kararlılığını operasyonel açıdan kritik mesafe eşiğini YOLOv8-v2'ye kıyasla iki ila üç kat geriye taşıyarak önemli ölçüde iyileştirmiştir. YOLO26-640 ve

YOLO26-1280'in Jetson üzerindeki tespit menzilleri (11.5 m ve 21.6 m), dizüstü ortamındaki karşılıklarını (9.0 m ve 18.3 m) geride bırakmıştır; bu iyileşmenin simülasyondaki kamera görüş alanı (FOV) açısında yapılan ayarlardan kaynaklandığı değerlendirilmektedir.

Mevcut değerlendirmenin birkaç sınırlılığı bulunmaktadır. Birincisi, tüm sonuçlar simüle edilmiş sensör verilerinden elde edilmiştir; mercek bozulması, atmosferik sis ve dinamik aydınlatma gibi etkenler Gazebo tarafından tam olarak yeniden üretilmemektedir. İkincisi, HIL kurgusundaki simülasyon haberleşme gecikmesi (~ 0.67 Hz) gerçek saha koşullarını tam yansıtmamaktadır; gerçek bir uçuşta bu kısıt büyük ölçüde ortadan kalkacaktır. Üçüncüsü, kaçınma mekanizması yalnızca tek tehdit senaryolarında test edilmiştir. Bununla birlikte, tespit bileşeni çoklu düşman varlığını destekleyecek biçimde tasarlanmıştır: sahnede birden fazla düşman tespit edildiğinde sistem, en büyük sınır kutusuna sahip olanı — dolayısıyla en yakın ve en tehlikeli olanı — öncelikli hedef olarak seçmektedir. Çoklu tehdit senaryolarının deneysel olarak doğrulanması gelecek çalışmalar kapsamında planlanmaktadır.

VI. SONUÇ

Bu çalışmada, otonom İHA'lar için YOLO26 tabanlı tehdit tespiti ve dost-düşman sınıflandırması, kural tabanlı adaptif kaçınma mekanizması ve daha önce görülmemiş dron tiplerinden saha-içi otonom veri toplama altyapısını kapsayan entegre bir sistem sunulmuş ve NVIDIA Jetson Orin Nano üzerinde Hardware-in-the-Loop ortamında doğrulanmıştır.

YOLO26-1280 modeli Jetson üzerinde 21.6 m tespit menzili ile YOLOv8-v2'nin (6.3 m) ve YOLO26-640'ın (11.5 m) çok ötesine geçmiş; sınıflandırma kararlılığı açısından da diğer mimarilere kıyasla belirgin üstünlük göstermiştir. Kural tabanlı kaçınma mekanizması %86.7 başarı oranı ile simülasyon ortamında etkin olduğunu kanıtlamıştır. Saha-içi otonom veri toplama altyapısı, görülmemiş bir hedefe ait 30 çerçeveyi insan müdahalesi olmaksızın tutarlı biçimde derlemiş; bu veri az örnek ile ince ayar için doğrudan kullanılabilir formata getirilmiştir.

Sonraki aşamada planlanmakta olan çalışmalar şu başlıkları kapsamaktadır: gerçek fiziksel İHA platformunda uçuş denemeleri, çok tehditli senaryoların değerlendirilmesi, simülasyon–model döngüsündeki entegrasyon darboğazının giderilmesi ve toplanan az örnekli verilerle YOLO26 modelinin yeni dron tiplerine ince ayar edilmesi.

REFERENCES

- [1] S. A. H. Mohsan, M. A. Khan, F. Noor, I. Ullah ve M. H. Alsharif, "Towards the Unmanned Aerial Vehicles (UAVs): A Comprehensive Review," *Drones*, cilt 6, sayı 6, s. 147, 2022.
- [2] D. Floreano ve R. J. Wood, "Science, technology and the future of small autonomous drones," *Nature*, cilt 521, ss. 460–466, 2015.
- [3] H. Shakhathreh ve ark., "Unmanned Aerial Vehicles (UAVs): A Survey on Civil Applications and Key Research Challenges," *IEEE Access*, cilt 7, ss. 48572–48634, 2019.
- [4] J. Redmon, S. Divvala, R. Girshick ve A. Farhadi, "You Only Look Once: Unified, Real-Time Object Detection," *Proc. CVPR*'de, 2016, ss. 779–788.
- [5] G. Wang, Y. Chen, P. An, H. Hong, J. Hu ve T. Huang, "UAV-YOLOv8: A Small-Object-Detection Model Based on Improved YOLOv8 for UAV Aerial Photography Scenarios," *Sensors*, cilt 23, sayı 16, s. 7190, 2023.

- [6] T. Ning, W. Wu ve J. Zhang, "Small Object Detection Based on YOLOv8 in UAV Perspective," *Pattern Analysis and Applications*, cilt 27, sayı 3, s. 103, 2024.
- [7] Y. Li, Q. Li, J. Pan, Y. Zhou, H. Zhu, H. Wei ve C. Liu, "SOD-YOLO: Small-Object-Detection Algorithm Based on Improved YOLOv8 for UAV Images," *Remote Sensing*, cilt 16, sayı 16, s. 3057, 2024.
- [8] L. Xu, Y. Zhao, Y. Zhai, L. Huang ve C. Ruan, "Small Object Detection in UAV Images Based on YOLOv8n," *Int. J. Computational Intelligence Systems*, cilt 17, makale no. 223, 2024.
- [9] K. He, X. Zhang, S. Ren ve J. Sun, "Deep Residual Learning for Image Recognition," *Proc. CVPR*'de, 2016, ss. 770–778.
- [10] V. Chandola, A. Banerjee ve V. Kumar, "Anomaly Detection: A Survey," *ACM Comput. Surv.*, cilt 41, sayı 3, ss. 1–58, 2009.
- [11] D. Gong ve ark., "Memorizing Normality to Detect Anomaly: Memory-Augmented Deep Autoencoder for Unsupervised Anomaly Detection," *Proc. ICCV*'de, 2019, ss. 1705–1714.
- [12] O. Vinyals, C. Blundell, T. Lillicrap, K. Kavukcuoglu ve D. Wierstra, "Matching Networks for One Shot Learning," *Advances in NeurIPS*, cilt 29, 2016.
- [13] J. Snell, K. Swersky ve R. Zemel, "Prototypical Networks for Few-shot Learning," *Advances in NeurIPS*, cilt 30, 2017.
- [14] B. Kang, Z. Liu, X. Wang, F. Yu, J. Feng ve T. Darrell, "Few-shot Object Detection via Feature Reweighting," *Proc. ICCV*, 2019, ss. 8420–8429.
- [15] O. Khatib, "Real-Time Obstacle Avoidance for Manipulators and Mobile Robots," *Int. J. Robot. Res.*, cilt 5, sayı 1, ss. 90–98, 1986.
- [16] J. van den Berg, M. Lin ve D. Manocha, "Reciprocal Velocity Obstacles for Real-Time Multi-Agent Navigation," *Proc. ICRA*'da, 2008, ss. 1928–1935.
- [17] F. Wang, X. Zhu, Z. Zhou ve Y. Tang, "Deep-Reinforcement-Learning-Based UAV Autonomous Navigation and Collision Avoidance in Unknown Environments," *Chinese Journal of Aeronautics*, cilt 37, sayı 3, ss. 237–257, 2024.
- [18] Y. Yin, Z. Wang, L. Zheng, Q. Su ve Y. Guo, "Autonomous UAV Navigation with Adaptive Control Based on Deep Reinforcement Learning," *Electronics*, cilt 13, sayı 13, s. 2432, 2024.
- [19] Ultralytics, "YOLOv26," *Ultralytics Documentation*. <https://docs.ultralytics.com/models/yolo26> (Erişim: 19 Mayıs 2026).